

2205-0266

# 基于超图卷积网络的用户微行为会话推荐

杨显鹏, 李晓楠, 李冠宇

大连海事大学 信息科学技术学院, 辽宁 大连 116026

**摘要:** 会话推荐系统因其仅利用用户短期会话信息进行推荐, 无需使用用户配置文件和长期历史信息等优点, 受到工业界和学术界的广泛关注。现有的会话推荐系统建模用户会话信息时将每一个会话构建为独立的图, 忽略了项目间的相关性, 且仅考虑单一的用户商品交互信息, 忽略了交互的多样性(如浏览、点击、加入购物车等)。针对上述问题, 本文提出了一种基于超图卷积网络的用户微行为会话推荐方法, 该方法首先将用户与项目的交互序列构建为超图, 以学习会话中项目间的高阶相关性, 利用超图卷积神经网络得到交互商品序列的嵌入; 然后, 将用户与商品交互时产生的一系列操作表征为“微行为序列”, 以丰富交互的多样性, 利用 GRU 网络学习得到微行为序列的嵌入; 最后, 将两者融合到一起, 为会话推荐系统得到更细粒度的嵌入表示。在数据集 Tmall 与 JDATA 中的大量实验表明, 在评价指标 P@20 与 MRR@20 中相比于基线方法推荐准确性有明显提升。

**关键词:** 超图; 推荐系统; 微行为; 会话推荐

**文献标志码:** A      **中图分类号:** TP391

## Hypergraph Convolutional Networks for Micro-behavior Encoding Session-based Recommendation

YANG Xianpeng, LI Xiaonan, LI Guanyu

Faculty of Information Science &amp; Technology, Dalian Maritime University, Dalian, Liaoning 116026, China

**Abstract:** Session recommendation system is widely concerned by industry and academia because it only uses short-term session information of users to make recommendations without using user profile and long-term history information. When modeling user session information, the existing session recommendation system constructs each session as an independent graph, ignores the correlation between items, only considers the single user commodity interaction information, and ignores the diversity of interactions (such as browsing, clicking, adding to shopping cart, etc.). To solve the above problems, this paper proposes a user micro-behavior session recommendation method based on hypergraph convolution network. The method first constructs the interaction sequence between users and items as a hypergraph to learn the high-order correlation between items in the session, and uses the hypergraph

**基金项目:** 国家自然科学基金(No.61976032, No.62002039)。

**作者简介:** 杨显鹏(1998—),男,硕士研究生,CCF 学生会员(J7622G),研究领域为智能信息处理;李晓楠(1992—),女,博士研究生,研究方向为知识图谱、图匹配;李冠宇(1963—),男,博士,教授,研究领域为智能信息处理,E-mail: liguanyu@dlmu.edu.cn。

**收稿日期:** 2022-00-00; **修回日期:** 2022-00-00

convolution neural network to get the embedding of the interactive product sequence. Then, a series of operations generated when users interact with goods are represented as "micro-behavior sequence" to enrich the diversity of interaction, and the embedding of micro-behavior sequence is obtained by using GRU network learning. Finally, the two are fused together to obtain a more fine-grained embedded representation for the session recommendation system. A large number of experiments in data sets Tmall and JDATA show that, compared with the baseline method, the recommendation accuracy of rating indicators P@20 and MRR@20 has been significantly improved.

**Key words:** Hypergraphs; recommendation system; micro-behavior; session recommendation

推荐系统旨在缓解当前网络上信息过载的问题,使用户不必接收过多不感兴趣的信息,以此来提升用户的浏览体验。大多数现有的推荐系统(如协同过滤)通常从长期的历史交互中学习用户的行为偏好,然而在许多应用场景中用户标识可能是未知的(如用户没有登陆),并且在会话期间只有用户当前的历史操作可用,在仅有用户短期交互信息的情况下传统推荐系统很难生成准确的推荐结果。为了解决这些问题近些年提出了基于会话的推荐系统<sup>[1]</sup>,它通过当前会话中用户已经完成的行为来预测即将发生的行为。

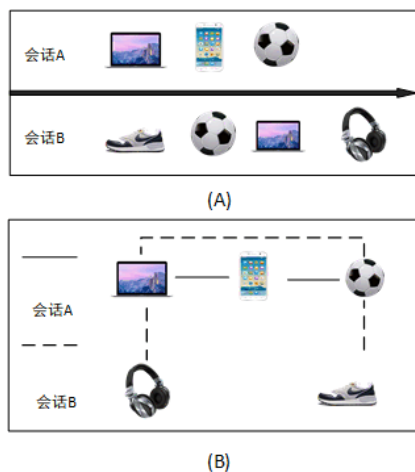


图1 将每个会话单独建模与建立全局图对比

Fig.1 Model each session individually and create a global graph comparison

随着会话推荐系统的发展,将图神经网络应用于会话中序列建模<sup>[10]</sup>的方法使得会话推荐的准确性取得非常明显的提升。但他们仅将每一个会话序列构建为一个独立的有向子图,项目之间是成对关系。然而它们忽略了会话中的项目与项目之间的关系是复杂的并非完全顺序依赖,且会话与会话之间也存在着一定的相互依赖关系。这将导致推荐模型不能捕获到完整的项目之间的相关性,造成推荐结果具有局限性。如

图1所示,用户A、B分别在一个会话期间内购买了{电脑,手机,足球},{球鞋,足球,电脑,耳机}。传统构建图的方法将会话A、B独立看待,每一个商品项目作为一个节点,按照商品出现顺序对各个节点进行简单连接,形成各自对应的会话图。这种方法忽略了会话A、B中相同项目之间的联系,为了捕获到不同会话中项目间更丰富的联系本文提出了将不同会话建模为一个超图,会话间通过公共节点进行相连。如图1B所示,两个会话通过公共节点进行连接后可以扩展不同商品之间的相关性即高阶相关性,例如{耳机,电脑,手机}这个子图是仅将每一个会话单独建图而捕捉不到的,且将图构建为无向图更适合学习项目之间相互的联系。

同时现有的方法仅利用用户交互的单一行为,即用户与商品交互的序列,本文中称为宏观行为(Macro-Behavior)。但用户与商品交互时的行为是多样的(如点击、浏览、加入购物车等),这些用户与商品的交互行为被称为“微行为”(Micro-Behavior),忽略了这些微行为信息将不能捕获到用户潜在的偏好。如图2所示,用户1与用户2有着相同的宏观行为,在仅关注宏观行为的推荐系统中,两用户会得到相同的推荐商品。但现实中两位用户最后选择了不同的商品,可能的原因是两位用户对同一商品的交互行为(微行为)的差异所隐含的潜在偏好没有正确的捕捉到所造成的。浏览商品在一定程度上并不影响用户的最终决策,但查看评论与加入购物车后用户更有可能在下一步进行购买操作。针对这种仅利用宏观序列不能捕获到用户潜在行为偏好的问题,本文通过向会话中加入每个宏观行为的微观行为序列作为辅助信息,以获得用户序列更细粒度的理解。

本文提出基于超图卷积的用户微行为推荐方法(Hypergraph Convolutional Networks for Micro-behavior Encoding Session-based Recommendation, HMSR)。HMSR首先将用户宏观行为构建为超

图, 每一个用户的会话构建为一条超边, 超边中所有的项目都是相互连通的, 超边之间通过共享的项目进行连接, 构成了包含项目级高阶相关性的超图。将宏观序列输入到超图中经超图卷积网络得到包含项目高阶相关性的宏观行为嵌入。然后将微观行为序列经 GRU 网络后输出得到包含微观行为相互依赖关系的微行为嵌入序列。两个序列融合得到总体的会话嵌入表示, 以此进行下一项推荐。



图2 用户微观行为对下一项预测结果的影响

Fig.2 The effect of user micro behavior on the next prediction result

本文主要贡献如下:

- (1) 通过构建超图来学习用户宏观行为序列的高阶相关性特征, 提高推荐的准确性。
- (2) 在宏观行为的基础上加入用户微行为, 构成更加细粒度的序列, 为学习用户偏好提供更多的特征参考。

## 1 相关工作

受相似用户倾向于购买相似物品的启发, 最早的基于会话的推荐方法大多基于最近邻居节点<sup>[2]</sup>, 这些方法需要一个相似度函数来计算相似度得分。另一些方法注意到利用顺序行为有助于预测下一个项目, 基于个性化马尔可夫链<sup>[3]</sup>的因子分解方法, 被应用于捕获用户的顺序行为和长期兴趣。Wang 等人提出了一种层次化表示模型<sup>[4]</sup> (HRM), 用层次化架构来改进马尔科夫链。然而, 基于马尔科夫链的方法并不适用于基于会话的推荐任务, 它们只粗略的考虑相邻项目之间的转换, 而不能捕获到正在进行的会话中蕴含的更复杂的高阶序列模式。

深度学习方法的快速发展, 为基于会话的推荐带来了显著的性能提升。递归神经网络<sup>[5][6]</sup> (Recurrent Neural Networks) 在序列信号建模方面表现出强大的

能力, 在推荐系统中得到了广泛的应用。GRU4Rec<sup>[7]</sup>是第一个在基于会话的推荐中应用 RNN 的工作, 它使用门控循环单元 (GRU) 来模拟用户顺序行为。此外, 由于会话作为正在进行的信息表征用户行为偏好的能力非常有限, 因此引入邻居信息来帮助对正在进行的会话建模。例如, Wang 提出了 CSRM<sup>[8]</sup>, 通过记忆网络合并邻居会话信息。为了更好的学习会话表示, NARM<sup>[9]</sup>中提出了一种注意池方法, 并被广泛的应用于后续的神经推荐方法中。然而, 他们只考虑单个项目作为推荐基准, 缺乏对会话组合信息的描述。

最近大部分方法都引入图神经网络 (Graph Neural Network, GNN) 来捕获复杂的会话转换关系。例如 SR-GNN<sup>[10]</sup>利用相邻项之间的转换来构造非加权会话图, 并使用门控神经网络提取转换关系。在此基础上 GGNN<sup>[12]</sup>通过提取局部上下文信息, 使用自注意网络捕获远距离位置之间的全局依赖关系。虽然基于 GNN 的模型优于包括 RNN 的其他方法, 但他们只是将每个会话构造为一个图, 并不能捕获到不同会话间复杂的高阶相关性。

一些方法将超图 (hypergraphs) 引入会话推荐中, DHCN<sup>[13]</sup>将每个会话作为一个超边来建模跨会话项关系, SHARE<sup>[14]</sup>使用滑动窗口来构建单个会话的超图来捕捉组意图。但是, 这种利用超图建模会话信息的方法仅使用宏观项目序列来生成会话特征表示, 不能充分利用会话数据中更细粒度级别的用户意图信息。

现有的大部分会话推荐都仅仅关注用户交互的项目的序列, 而忽略了用户对每个项目所做的详细操作。与粗粒度的项目序列相比, 对每个项目执行不同操作的细粒度序列能够更准确的反应用户的意图和偏好。已有的将微观行为纳入会话推荐的工作<sup>[16][17][18]</sup>只是用 RNN 模拟微观行为的顺序模式。然而微观行为往往是相互关联的, 基于 RNN 的会话推荐模型很难捕提高阶关系。

综合图神经网络表示宏观项目会话间项目转换关系的优越性能, 和添加微行为序列捕获更细粒度的用户偏好的能力, 提出了本文的方法。

## 2 方法

本节首先介绍本文将要解决的问题、使用的概念和定义。然后介绍如何基于输入的宏观序列构建超图, 并详细介绍如何使用超图卷积网络聚合宏观用户操作序列与微观用户操作序列, 得到融合了两种序列的会话嵌入, 最终生成推荐。

## 2.1 问题描述

融合用户微观行为的会话推荐的主要目的是将会话宏观序列构建为超图以捕获会话间项目的高阶相关性,并融合微观行为学习到更细粒度的用户潜在偏好表示,以提升推荐系统的推荐准确度。

给定宏观项目集合(用户交互的商品)

$I = \{i_1, i_2, i_3, \dots, i_N\}$ ,  $N$  表示宏观项目的个数,微观行为为集合(用户与商品进行交互时所进行的操作,如点击、加入购物车、查看评论等)  $O = \{o_1, o_2, o_3, \dots, o_K\}$

,  $K$  表示微观操作的个数。对于每一个给定的用户项目会话和其微观操作集合,

$$s_i^{item} = \{i_{i,1}, i_{i,2}, i_{i,3}, \dots, i_{i,m}, \dots, i_{i,M}\} \quad i_{i,m} \in I \quad \text{与}$$

$$s_i^{operation} = \{o_{i,1}, o_{i,2}, o_{i,3}, \dots, o_{i,m}, \dots, o_{i,M}\}, o_{i,m} \in O,$$

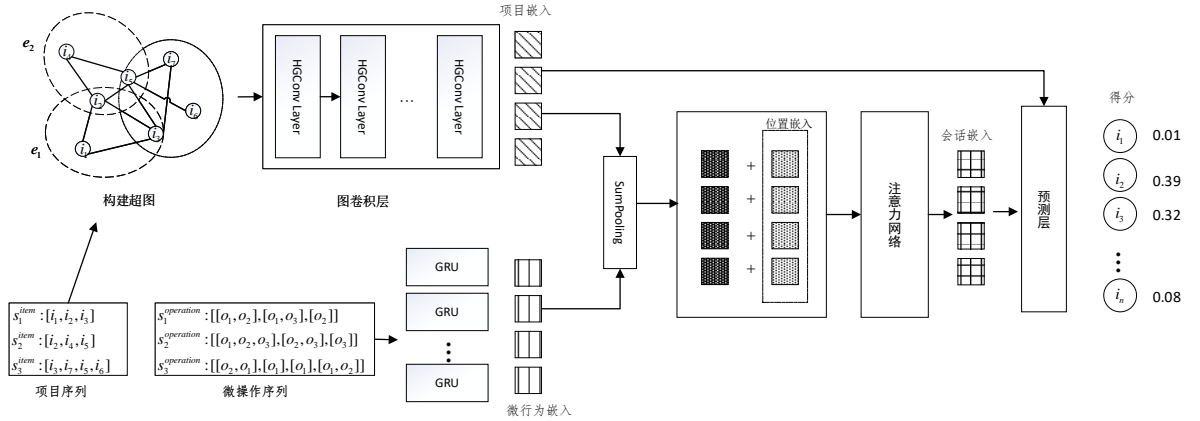


图3 模型总体框架

FIG.3 Overall framework of model

## 2.3 超图构建

超图<sup>[11]</sup>的定义为:  $G = (V, E)$ ,  $V$  是  $I$  的集合,  $E$  是  $J$  条超边的集合( $J$  为合并后所有微观操作个数的和)。每一个超边  $e \in E$  包含两个或更多的节点,并被分配一个正权值  $W_{ee}$ ,  $W \in R^{J \times J}$  为所有权重构成的一个对角矩阵。整个超图可以用矩阵  $H \in R^{N \times J}$  来表示,其中  $H_{ie} = \begin{cases} 1 & e \in E \\ 0 & e \notin E \end{cases}$ 。每一个顶点和超边

$M$  为一个会话的长度。将宏观操作序列与微观操作序列经分别处理后,融合得到最终的会话嵌入表示。通过推荐模块得到每一个项目在对应输入会话序列中的得分  $y$  以完成推荐,其中得分最高的项即为  $i_{i,M+1}$ 。

## 2.2 模型框架

模型总体框架如图3所示,首先将会话信息中宏观序列相同的连续微观操作项进行合并,以提升信息在超图中传播的速度。将所有会话的宏观项目构建为超图,每一条超边都是一条会话,超图中所有节点是相互连接的。然后将宏观序列输入到超图中进行传播,得到宏观项目嵌入。每一个宏观项目所对应的微观序列都输入到一个 RNN 网络中以捕获微操作行间的顺序特征并以嵌入形式表示,为了避免产生梯度消失的问题,本文使用 GRU 网络。将宏观行为嵌入与微观行为嵌入进行融合后,通过注意力网络获得最终的会话表示  $s$ ,并计算出所有候选项的得分,完成推荐。

的度被依次定义为:超边的度矩阵  $D_{ii} = \sum_{e=1}^J W_{ee} H_{ie}$ ;

所有顶点的度矩阵  $B_{ii} = \sum_{i=1}^N H_{ie}$ 。 $D$  和  $B$  都是对角矩阵。

在文献<sup>[13]</sup>中已经证明应用超图将全部用户会话统一建模可以捕获高阶用户偏好的更细粒度的表示,本文参考这种方法将所有用户的宏观序列构建为一个超图,每一个超边都为一条会话,超边与超边之间所有的节点都是相连的,构成一个无向多重图。每一个会话都按<sup>[18]</sup>的方法进行处理,例如,对于一个宏观序列:  $s^{item} = [i_1, i_1, i_1, i_2, i_3, i_3]$  与其对应的微观序列:



$s^{operation} = [o_1, o_2, o_3, o_2, o_2, o_3]$ ，传统的方法是直接按照宏观序列进行图的构建（图 3A），以这种方法构造出来的图有过多的边又连接到项目本身，不利于项目序列沿着超图的边在不同项目间进行传递。因此，本文将连续的宏观行为与对应的微观行为分别进行合并，如图 4B 所示：对于会话中前三个操作都是针对  $i_1$  所进行，因此可以将  $(o_1, o_2, o_3)$  进行合并，同理对于两个连续对  $i_3$  的会话进行同样的合并，得到  $s^{item} = [i_1, i_2, i_3]$  与  $s^{operation} = [(o_1, o_2, o_3), (o_2), (o_2, o_3)]$ 。这种构建方法的目的是确保构建出的超图可以沿着不同边对宏观序列中所包含的微观信息进行传播。




图 4 不同方式的会话表示方法

FIG.4 Different ways to represent sessions

为了在会话推荐系统中捕获到超成对关系，本文将所有宏观会话构建为一个超图如图 4 所示， $G = (V, E)$ ，每一个宏观会话  $s^{item} = \{i_{1,1}, i_{1,2}, i_{1,3}, \dots, i_{i,m}, \dots, i_{i,M}\}$  作为一条超边，超边中每一个项目  $i_{i,m} \in I$  作为一个节点。在超图中，如果任意两个超边有公共的顶点，那么它们就是联通的。此外超边内的所有顶点都是连接的，因此超图包含了项目之间的高阶非配对关系，这可以用于全局层面上项目的特征表示。超图是一个无向图，因此可以更好地捕获到项目序列中不同项目之间复杂的高阶关系。

## 2.4 超图卷积模块

传统的基于普通图的会话推荐方法都是将每一个会话单独的构建为一个图，以此来获得项目与项目之间在当前会话中的关系，而忽略了会话与会话之间不同项目的联系。超图卷积层的作用是获取每一个会话中与不同会话间项目与项目多对多的高阶关系，在超图上定义卷积运算的主要挑战是如何传播邻居节点的信息。参考<sup>[10][21]</sup>中所提出的方法，提出了本文的超图卷积网络：

$$h_v^{l+1} = D^{-1} H W B^{-1} H^T h_v^l \quad (1)$$

超图卷积可以看作在超图结构上进行“顶点-超边-顶点”特征转换的两级细化。 $H^T h_v^l$  是顶点到超边的信息聚合，再与  $H$  进行相乘将来自超边的信息聚集到节点。最终通过超图卷积模块获得该项目在每层的嵌入效果。对于一个给定的项目  $i_m$ ，在卷积的每一层中都会得到  $i_m$  的嵌入表示，对每一层最终的得到的嵌入值进行平均得到最终的全局表示：

$$h_{i_m} = \frac{1}{L+1} \sum_{l=0}^L h_{i_m}^{l+1} \quad (2)$$

在一个会话中，将所有项目集合表示为：

$$h_i^{item} = [h_{i,1}^{item}, h_{i,2}^{item}, \dots, h_{i,m}^{item}, \dots, h_{i,M}^{item}]。$$

### 2.4.2 微观序列嵌入

用户与商品交互时的微行为可以体现出用户对不同商品的喜好程度，同样的用户与每一个商品交互的微行为序列之间也存在着一种顺序关系，因此本文使用 GRU 网络来捕获微行为序列之间的相互依赖关系。

对于每一个微观操作  $o_k \in O$ ，参考<sup>[18]</sup>的方法，构建一个操作嵌入矩阵。对于输入的每一个微观操作序列  $s_i^{operation} = [o_{i,1}, o_{i,1}, \dots, o_{i,M}]$ ，其中  $o_{i,m} = [o_1, \dots, o_k]$ 。将每一个  $o_{i,m}$  中的微操作在操作嵌入矩阵中查找后得到其嵌入表示  $\{e_{o_1}, \dots, e_{o_k}\}$ 。会话中每一个项目对应的微观操作集合最终的表示为：

$$h_j^m = GRU(e_{o_j}, h_{j-1}^m; \Phi_{GRU}) \quad (3)$$

其中  $k \geq j \geq 1$ ， $\Phi_{GRU}$  表示所有的 GRU 网络中的参数。对每一个微行为序列，取序列中的最后一项结果代表整个序列，即  $h^m = h_k^m$ 。因此，每一个宏观会话对应的微观序列嵌入可以表示为：

$$h_i^{operation} = [h_{i,1}^{operation}, h_{i,2}^{operation}, \dots, h_{i,m}^{operation}, \dots, h_{i,M}^{operation}]。$$

### 2.4.3 信息融合层

在获得项目宏观序列和微观序列的嵌入之后, 本文采用 SumPooling 的方法将两个嵌入进行融合:

$$\mathbf{h}_m^* = \text{SumPooling}(\mathbf{h}_m^{\text{item}}, \mathbf{h}_m^{\text{operation}}) \quad (4)$$

$\mathbf{h}_m^*$  是会话序列中第  $m$  项的最终表现形式, 以得

到每个会话的最终嵌入, 例如:  $\mathbf{s} = [\mathbf{h}_1^*, \mathbf{h}_2^*, \dots, \mathbf{h}_M^*]$ 。

位置嵌入是 Transformer<sup>[7]</sup>中提出的一种技术, 已经在许多需要记忆项目位置信息的工作中被应用。将项目的位置信息进行编码加入到会话嵌入中, 在一定程度上可以获得更好的推荐效果。本文使用一个可学习的位置矩阵  $\mathbf{P}_r \in R^{M \times d}$  (其中  $M$  是当前序列的长度), 将位置矩阵中  $\mathbf{p}_{M-m+1}$  项与会话嵌入  $\mathbf{s} = [\mathbf{h}_1^*, \mathbf{h}_2^*, \dots, \mathbf{h}_m^*]$  中第  $m$  个项目的全局嵌入  $\mathbf{h}_m^*$  并置, 应用非线性变换计算项目  $i_m$  位置嵌入, 公式:

$$\mathbf{x}_i^* = \tanh(\mathbf{W}_1(\mathbf{h}_m^* \parallel \mathbf{p}_{M-m+1}) + \mathbf{b}) \quad (5)$$

其中  $\mathbf{W}_1 \in R^{d \times 2d}$  和  $\mathbf{b} \in R^d$  是可学习参数,  $\parallel$  表示连接操作。

会话的表示与学习到的项目信息密切相关, 为了获得会话的表示, 将会话序列中涉及的项目信息进行平均计算:

$$\mathbf{s}^* = \frac{1}{M} \sum_{m=1}^M \mathbf{h}_m^* \quad (6)$$

将得到的基于位置的嵌入会话信息  $\mathbf{x}_i^*$  和会话表

示  $\mathbf{s}^*$  通过软注意力机制(soft-attention)计算权重:

$$\mathbf{a}_i = \mathbf{q}^T (\mathbf{W}_2 \mathbf{x}_i^* + \mathbf{W}_3 \mathbf{s}^* + \mathbf{c}) \quad (7)$$

其中  $\mathbf{W}_2, \mathbf{W}_3 \in R^{d \times d}$ ,  $\mathbf{q}, \mathbf{c} \in R^d$  是可学习的参数。

因此会话的最终表示通过线性组合操作获得:

$$\mathbf{S} = \sum_{m=1}^M \mathbf{a}_i \mathbf{h}_i^* \quad (8)$$

### 2.5 生成推荐

对于一个给定的会话  $s_i = \{s_i^{\text{item}}, s_i^{\text{operation}}\}$ ,

通过将其最终表示  $\mathbf{S}$  与超图卷积网络中生成的  $\mathbf{h}_{i_m}$  做内积得到项目得分:

$$\hat{\mathbf{z}}_i = \mathbf{S}^T \mathbf{h}_{i_m} \quad (9)$$

使用 softmax 函数计算每个项目成为会话中下一个项目的概率:

$$\mathbf{y} = \text{softmax}(\hat{\mathbf{z}}) \quad (10)$$

为了优化模型, 本文采用一个在推荐系统领域被广泛应用的交叉熵损失函数:

$$L_r = -\sum_{i=1}^N y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i) \quad (11)$$

其中  $\mathbf{y}$  为独立热编码,  $\mathbf{y}_m = (1, 0)$  分别表示用户

会与项目  $i_m$  产生交互或者不会。为了最小化损失函数, 得到最优推荐, 优化模型中采用了 Adam 优化方法。

## 3 实验与评估

### 3.1 数据集与预处理

本次实验中采用了两个公开的数据集: Tmall 与 JDATA。Tmall 数据集来自于购物网站淘宝与天猫, 用户与商品的交互行为包含点击、购买、点赞与加入购物车等四种行为。JDATA 来自于购物平台京东, 用户与商品的交互行为包括浏览、下单、关注、评论与加入购物车等五种行为。对于两个数据集使用最常见的预处理方法, 首先去除掉只有一个交互项目的会话, 同时去掉出现次数少于五次的商品, 并将数据集按照 70%、10%、20% 划分为训练集、验证集、测试集。经过处理后, 两个数据集的数据统计情况见表 1。

表 1 数据集统计信息

Table1 Data set statistics

数据集	Tmall	JDATA
会话数	818479	455481
商品数量	40728	28356
操作数	4	5

### 3.2 评价指标

为了评价推荐系统的推荐准确性, 本文采用两个常用的基线对比方法: Precision(P)与 Mean Reciprocal Rank(MRR)。

$P@K$  表示的是测试集中被正确推荐的项目出现在前  $K$  个项目的比例, 计算公式为:

$$P@K = \frac{n_{hit}}{N} \quad (12)$$

$N$  为测试集中的序列数目,  $n_{hit}$  为推荐项目中排名前  $K$  的项目数。

$MRR@K$  为用户的真实目标值在生成的前  $K$  项推荐列表中序号的倒数平均值, 如果真实目标在推荐列表中第一项那么  $MRR$  值为 1, 如果在第二项那么  $MRR$  值为 0.5, 如果推荐项目中没有真实推荐项, 则  $MRR$  值为 0. 取所有测试集中  $MRR$  值的平均值作为最终的  $MRR$  值。公式为:

$$MRR@K = \frac{1}{N} \sum_{i_{target}} \frac{1}{rank(i_{target})} \quad (13)$$

$P@K$  与  $MRR@K$  的值越高, 推荐的效果越好。

### 3.3 实验结果与分析

#### 3.3.1 参数设置

本文的实验中使用 Adam 优化器, 批大小 (batch size) 设置为 512, 初始嵌入大小 (embedding size) 设置为 100, 经过调整其他参数可以得到在 Tmall 数据集上学习率 0.001, 网络层数 1 得到最佳效果。在 JDATA 数据集上, 学习率为 0.01, 网络层数设置为 3 得到最佳效果。图 4、图 5 分别为在两个数据集上将网络层数设置为 [1,3,5,10] 与嵌入大小设置为 [0.0005,0.001,0.01,0.1] 的情况下对推荐结果的影响。




图 5 网络层数对结果的影响

Fig.5 The impact of network layers on the results




图 6 学习率对推荐效果的影响

Fig.6 The influence of learning rate on recommendation effect

从图 5、图 6 可以看出, 对于 Tmall 数据集在网络层数为 1、学习率为 0.001 时可以得到最佳效果, 对于 JDATA 数据集在网络层数为 3、学习率为 0.01 时可以得到最佳效果。出现这种差异的原因, 可能是由于 Tmall 数据集的项目数量远高于 JDATA 数据集的数据量, 因此更小的学习率可以捕获到更细致的会话特征。而京东数据集项目数量相对较少, 增加网络层数可以获得更精确的项与项之间的关系。

#### 3.3.2 算法对比

为了证明本文提出的算法的优越性, 选取了几种当下最热门的方法进行对比:

FPMC<sup>[20]</sup>: 一种基于个性化马尔科夫链的序列推荐算法。

GRU4Rec<sup>[7]</sup>: 一种使用循环神经网络与注意力机制的会话推荐算法。

NARM<sup>[9]</sup>: 一种基于 GRU 网络的会话推荐模型, 并考虑到用户长期兴趣的影响。

SR-GNN<sup>[10]</sup>: 使用 GRU 网络获取项目的嵌入表示, 主要通过关注最后一个项目来计算会话的特征表示。

DHCN<sup>[13]</sup>: 提出了基于超图的神经网络和基于线图的神经网络来捕获会话的高阶关系, 使用自监督学习来增强超图建模效果。

RIB<sup>[15]</sup>: 第一个使用 GRU 网络将微行为融合进会话系统的方法

MKM-SR<sup>[17]</sup>: 最新的使用了 GNN 与 GRU 网络分别捕获项目嵌入与微行为嵌入的会话推荐模型。

表 2 推荐性能对比

Table 2 Recommended performance comparison

	Tmall		JDATA	
	P@20	M@20	P@20	M@20
FPMC	16.06	7.32	7.53	2.62
GRU4REC	10.93	5.89	35.35	13.96
NARM	23.3	10.7	36.87	16.83
SR-GNN	27.57	13.72	40.59	15.97
DHCN	31.42	15.05	44.65	17.25
RIB	26.45	12.5	37.24	14.13
MKM-SR	29.26	13.79	42.57	17.58
OURS	<b>33.59</b>	<b>17.02</b>	<b>47.20</b>	<b>21.36</b>

通过对比几种算法在 Tmall 与 JDATA 数据集上的 P@20, MRP@20 的值可以得出如下结论:

大部分采用深度学习方法的模型最终推荐准确性都超过了采用矩阵分解和一阶马尔科夫链获取用户偏好的 FPMC 模型, 证明深度学习的方法对会话推荐的影响是显著的。

同样采用 GRU 网络建模用户序列表示的 GRU4REC 与 NARM 两种方法相比后者推荐效果更好, 原因是 NARM 方法额外添加了注意力层使模型可以区分会话中不同项目的重要性程度。

SR-GNN 与 DHCN 都是将会话序列转化为一个图, 通过使用图卷积网络获取项目之间的依赖关系。它们的推荐效果优于使用 RNN 网络的模型, 这体现了项目之间依赖关系的重要性。其中 DHCN 将会话图转换为超图不同会话作为超边通过相同项进行连接, 相较于传统项目顺序连接图可以更好地捕获会话中项目和项目之间的高阶依赖关系, 因此 DHCN 的表现效果更好。

RIB 与 MKM-SR 在宏观会话序列的基础上加入了用户的微行为信息, 来捕获用户行为中更细粒度的信息。其中 RIB 使用 GRU 来进行构建用户宏观行为序列与微观行为序列, 推荐准确性优于表中其他使用 GRU 的模型。MKM-SR 进一步的使用图卷积网络编码用户宏观行为, 使用 GRU 构建微行为为嵌入并添加知识图谱作为辅助信息, 因此它的结果优于 RIB。

相较于以上方法, 本文所提出的 HMSR 方法将用户宏观行为通过构建超图来捕获到宏观行为之间的高阶信息, 并添加用户微行为信息以获得更细粒度的用户偏好表示, 在所有对比模型中达到最优效果, 证明了本方法的有效性。

### 3.3.3 消融实验

在本节中为了探究超图与微行为对模型效果的影响, 设计了两种对比模型 HMSR-NH 与 HMSR-NM。其中 HMSR-NH 为在网络结构中去掉超图构建与超图卷积网络的部分, 使用其他微行为推荐方法中常用的 GGNN 网络替代。HMSR-NM 为在模型中去掉微行为建模的部分, 用户宏观行为通过超图卷积网络后直接生成会话嵌入并进行推荐。实验结果如图 7 所示。

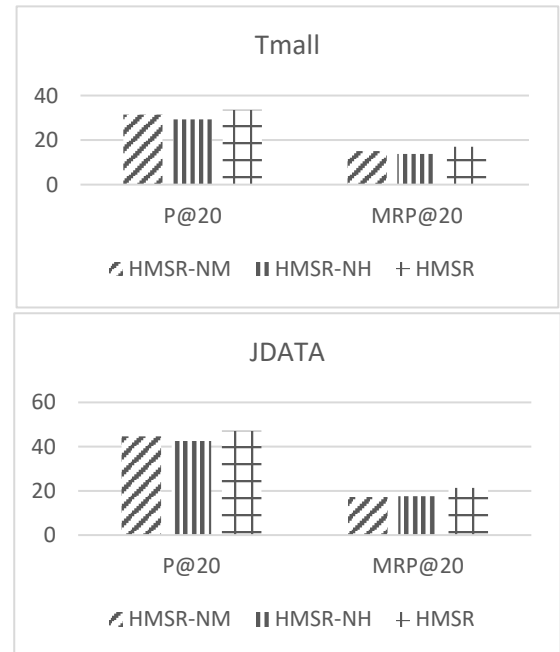


图 7 在两种数据集上的消融实验结果

Fig.7 Results of ablation experiments on two data sets

通过消融实验可以证明, 本文提出的超图构建用户宏观行为序列以捕获项与项之间的高阶关系, 与融合项目的微观行为以捕获不同用户对同一序列的不同喜好程度的方法是有效的。



## 4 结束语

本文提出了基于超图卷积网络的用户微行为会话推荐方法,将用户宏观序列构建为超图获得会话中商品间的高阶依赖关系,并融合每一个宏观操作的微观操作序列,获得更细粒度的用户潜在偏好,共同提升推荐系统的准确性。

目前本工作的局限性是只采用 RNN 来捕获用户微行为序列特征,未能深度挖掘用户微行为信息中的深层语义联系。未来工作的重点是,将微行为信息同样构建为超图结构,以捕获到微行为序列间的语义转换关系,更好的提升推荐性能。

## 参考文献:

- [1] 赵海燕,赵佳斌,陈庆奎,曹健.会话推荐系统[J].小型微型计算机系统,2019,40(09):1869-1875.
- [2] Zhao H Y, Zhao J B, Cao J. Session-based Recommendation System[J]. Journal of Chinese Computer Systems, 2019,40(09):1869-1875.
- [3] 王梅瑞. 基于记忆网络的协同会话型推荐系统研究[D]. 山东大学,2019.
- [4] Wang M R. Research on Collaborative Session-based Recommendation with Memory Networks[D]. Shandong University,2019.
- [5] Jia H, Yang J. Research on joint ranking recommendation model based on Markov chain[J]. Concurrency and Computation: Practice and Experience, 2020, 32(6): e5191.
- [6] Wang P, Guo J, Lan Y, et al. Learning hierarchical representation model for next basket recommendation [C]//Proceedings of the 38th International ACM SIGIR conference on Research and Development in Information Retrieval. 2015: 403-412.
- [7] 曹万平,周刚,陈黎,崔兰兰.基于会话的图卷积递归神经网络推荐模型[J].四川大学学报(自然科学版),2021,58(02):66-72.DOI:10.19907/j.0490-6756.2021.022002.
- [8] Cao W P, Zhou G, Chen L, et al. Session-based graph convolutional recurrent neural networks recommendation model[J]. Journal of Sichuan University(Natural Science Edition),2021,58(02):66-72.DOI:10.19907/j.0490-6756.2021.022002.
- [9] Dobrovolny M, Selamat A, Krejcar O. Session based recommendations using recurrent neural networks-long short-term memory[C]//Asian Conference on Intelligent Information and Database Systems. Springer, Cham, 2021: 53-65.
- [10] Hidasi B, Karatzoglou A, Baltrunas L, et al. Session-based recommendations with recurrent neural networks[J]. arXiv preprint arXiv:1511.06939, 2015.
- [11] Wang M, Ren P, Mei L, et al. A collaborative session-based recommendation approach with parallel memory modules[C]//Proceedings of the 42nd international ACM SIGIR conference on research and development in information retrieval. 2019: 345-354.
- [12] Li J, Ren P, Chen Z, et al. Neural attentive session-based recommendation[C]//Proceedings of the 2017 ACM on Conference on Information and Knowledge Management. 2017: 1419-1428.
- [13] Wu S, Tang Y, Zhu Y, et al. Session-based recommendation with graph neural networks[C]//Proceedings of the AAAI conference on artificial intelligence. 2019, 33(01): 346-353.
- [14] 胡秉德,王新根,王新宇,宋明黎,陈纯.超图学习综述:算法分类与应用分析[J].软件学报, 2022, 33: 498-523. DOI:10.13328/j.cnki.jos.006353.
- [15] Hu B D, Wang X G, Wang X Y, et al. Survey on Hypergraph Learning: Algorithm Classification and Application Analysis[J]. Journal of Software, 2022, 33: 498-523.DOI:10.13328/j.cnki.jos.006353.
- [16] Li Y, Tarlow D, Brockschmidt M, et al. Gated graph sequence neural networks[J]. arXiv preprint arXiv:1511.05493, 2015.
- [17] Xia X, Yin H, Yu J, et al. Self-supervised hypergraph convolutional networks for session-based recommendation[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2021, 35(5): 4503-4511.
- [18] Wang J, Ding K, Zhu Z, et al. Session-based recommendation with hypergraph attention networks[C]//Proceedings of the 2021 SIAM International Conference on Data Mining (SDM). Society for Industrial and Applied Mathematics, 2021: 82-90.
- [19] Zhou M, Ding Z, Tang J, et al. Micro behaviors: A new perspective in e-commerce recommender systems [C]//Proceedings of the eleventh ACM international conference on web search and data mining. 2018: 727-735.
- [20] Gu Y, Ding Z, Wang S, et al. Hierarchical user profiling for e-commerce recommender systems[C]//Proceedings of the 13th International Conference on Web S

- earch and Data Mining. 2020: 223-231.
- [17] Meng W, Yang D, Xiao Y. Incorporating user micro-behaviors and item knowledge into multi-task learning for session-based recommendation[C]//Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval. 2020: 1091-1100.
- [18] Yuan J, Ji W, Zhang D, et al. Micro-Behavior Encoding for Session-based Recommendation[J]. arXiv preprint arXiv:2204.02002, 2022.
- [19] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [20] Rendle S, Freudenthaler C, Schmidt Thieme L. Factoring personalized markov chains for next-basket recommendation[C]//Proceedings of the 19th international conference on World wide web. 2010: 811-820.
- [21] Peng D, Zhang S. GC-HGNN: A global-context supported hypergraph neural network for enhancing session-based recommendation[J]. Electronic Commerce Research and Applications, 2022, 52: 101129.

1.

杨显鹏；

2.

辽宁省大连市甘井子区凌海路 1 号大连海事大学网络信息中心 (116026);

3.

yang\_xianpeng@foxmail.com

13898581427

2205-0266

修改说明:

**问题 1:** 在创新性描述中, 对与文献 10 的差异, 做些说明。虽然有引用参考 10、受 10 的启发等, 但是还是没有很明确本文方法在文献 10 上的具体工作。

**修改:** 参考文献[10]作为第一篇在会话推荐中应用图神经网络建模会话信息的文章, 对本文提出的方法具有启发式的影响。在文献[10]的基础上许多改进式的方法被提出, 本文在对宏观行为建模成超图的灵感主要来

源于文献[13]。本文将文献[13]中对于建模会话信息为超图的方法进行借鉴作为本文其中一个模块, 已经在 2.3 节进行标注。

**问题 2:** 将连续的宏观行为与对应的微观行为分别进行合并 (图 4B) --建议同时要给出合并方法的描述, 而不仅是见图。

**修改:** 图 4 展示了对微行为序列的进一步处理, 将一段用户会话信息中连续的对同一项目的微观操作序列进行合并, 可以确保依据宏观行为会话建模成的超图传递信息时是依据宏观行为发生的顺序传递, 且也保证了宏观行为序列与微观行为序列的一一对应关系。已在文中图 4 上方添加详细描述。

**问题 3:** 论文的开始部分建议简略一些, 看起来写得有些啰嗦。

**修改:** 修改重新组织精炼了语言, 在文中对引言部分所举例子进行了精炼。